



**Aristotle University of Thessaloniki**

# **Πρόβλεψη Χρηματιστηριακών Τιμών με Νευρωνικά Δίκτυα**

Author:

**Γεώργιος Κουφετίδης (ΑΕΜ 4432)**

# Περιεχόμενα

|           |                                             |           |
|-----------|---------------------------------------------|-----------|
| <b>1</b>  | <b>Εισαγωγή</b>                             | <b>2</b>  |
| <b>2</b>  | <b>Μαθηματική Διατύπωση του Προβλήματος</b> | <b>2</b>  |
| <b>3</b>  | <b>Χαρακτηριστικά Εισόδου</b>               | <b>3</b>  |
| <b>4</b>  | <b>Χρονοσειριακό Παράθυρο Εισόδου</b>       | <b>4</b>  |
| <b>5</b>  | <b>Κανονικοποίηση Δεδομένων</b>             | <b>5</b>  |
| <b>6</b>  | <b>Χρονικός Διαχωρισμός Δεδομένων</b>       | <b>5</b>  |
| <b>7</b>  | <b>Άμεση Πολυ-Εξοδική Πρόβλεψη</b>          | <b>6</b>  |
| <b>8</b>  | <b>Convolutional Neural Network (CNN)</b>   | <b>6</b>  |
| <b>9</b>  | <b>Time Delay Neural Network (TDNN)</b>     | <b>7</b>  |
| <b>10</b> | <b>Μοντέλο CNN--LSTM</b>                    | <b>7</b>  |
| <b>11</b> | <b>Loss function</b>                        | <b>8</b>  |
| <b>12</b> | <b>Βελτιστοποίηση</b>                       | <b>8</b>  |
| <b>13</b> | <b>Ανακατασκευή Προβλεπόμενης Τιμής</b>     | <b>9</b>  |
| <b>14</b> | <b>Εκτίμηση Αβεβαιότητας</b>                | <b>9</b>  |
| <b>15</b> | <b>Baseline Μοντέλα</b>                     | <b>10</b> |
| <b>16</b> | <b>Πειραματικός Σχεδιασμός</b>              | <b>10</b> |
| <b>17</b> | <b>Περιορισμοί</b>                          | <b>11</b> |
| <b>18</b> | <b>Αποτελέσματα</b>                         | <b>11</b> |
| <b>19</b> | <b>Συμπεράσματα</b>                         | <b>17</b> |
| <b>20</b> | <b>Python Code</b>                          | <b>18</b> |

# 1 Εισαγωγή

Η πρόβλεψη χρηματιστηριακών τιμών αποτελεί ένα δύσκολο πρόβλημα χρονοσειριακής μοντελοποίησης. Οι τιμές των χρηματοοικονομικών τίτλων επηρεάζονται από πολλούς παράγοντες, όπως ιστορική συμπεριφορά τιμών, όγκος συναλλαγών, μεταβλητότητα, οικονομικές ανακοινώσεις, νέα αγοράς και ψυχολογία επενδυτών. Εξαιτίας αυτών των παραγόντων, η ακριβής πρόβλεψη μίας μελλοντικής τιμής δεν είναι γενικά εφικτή με απόλυτη βεβαιότητα.

Παρόλα αυτά, η χρήση μοντέλων μηχανικής μάθησης επιτρέπει τη μελέτη πιθανών σχέσεων μεταξύ ιστορικών χαρακτηριστικών και μελλοντικών αποδόσεων. Στην εργασία αυτή, το πρόβλημα δεν αντιμετωπίζεται ως απλή πρόβλεψη της επόμενης ημέρας, αλλά ως πρόβλεψη ολόκληρης μελλοντικής τροχιάς. Δηλαδή, για κάθε ημερομηνία αναφοράς, το μοντέλο προβλέπει αποδόσεις για πολλές μελλοντικές ημέρες.

Η προσέγγιση αυτή έχει ενδιαφέρον επειδή επιτρέπει την κατασκευή προβλεπόμενης καμπύλης τιμών. Έτσι, αντί το αποτέλεσμα να είναι μόνο ένα σημείο, όπως η τιμή της επόμενης ημέρας, παράγεται μία πλήρης μελλοντική πορεία. Για παράδειγμα, αν ο μέγιστος ορίζοντας είναι πέντε έτη, τότε το μοντέλο παράγει προβλέψεις για κάθε μελλοντική χρηματιστηριακή ημέρα μέχρι περίπου τις 1260 ημέρες.

Σκοπός της εργασίας είναι η μαθηματική διατύπωση και υπολογιστική υλοποίηση ενός τέτοιου προβλήματος. Η εργασία επικεντρώνεται στα εξής σημεία:

- στον μετασχηματισμό των τιμών σε λογαριθμικές αποδόσεις,
- στη δημιουργία χρονοσειριακών παραθύρων εισόδου,
- στην πολυ-εξοδική πρόβλεψη πολλών χρονικών οριζόντων,
- στη σύγκριση διαφορετικών νευρωνικών αρχιτεκτονικών,
- και στην αξιολόγηση του μοντέλου με κατάλληλες μετρικές.

## 2 Μαθηματική Διατύπωση του Προβλήματος

Έστω ότι έχουμε μία χρηματοοικονομική χρονοσειρά τιμών κλεισίματος:

$$\{P_t\}_{t=1}^T,$$

όπου  $P_t > 0$  είναι η τιμή κλεισίματος την ημέρα  $t$  και  $T$  είναι το πλήθος των διαθέσιμων ημερήσιων παρατηρήσεων.

Η απευθείας πρόβλεψη της τιμής  $P_{t+k}$  δεν είναι πάντα η καλύτερη επιλογή, επειδή οι τιμές διαφορετικών μετοχών βρίσκονται σε διαφορετικές κλίμακες. Για τον λόγο αυτό, ορίζουμε τη λογαριθμική απόδοση για χρονικό ορίζοντα  $k$  ως:

$$r_{t,k} = \ln \left( \frac{P_{t+k}}{P_t} \right).$$

Ο στόχος του μοντέλου είναι να προβλέψει την ποσότητα  $r_{t,k}$  για πολλούς μελλοντικούς ορίζοντες  $k$ . Αν η πρόβλεψη του μοντέλου είναι  $\hat{r}_{t,k}$ , τότε η αντίστοιχη προβλεπόμενη τιμή δίνεται από:

$$\hat{P}_{t+k} = P_t e^{\hat{r}_{t,k}}.$$

Άρα η μοντελοποίηση γίνεται στον χώρο των αποδόσεων, ενώ η τελική απεικόνιση μπορεί να γίνει στον χώρο των τιμών.

Για μέγιστο χρονικό ορίζοντα  $H$ , ορίζουμε το διάνυσμα στόχου:

$$\mathbf{y}_t = \begin{bmatrix} r_{t,1} \\ r_{t,2} \\ \vdots \\ r_{t,H} \end{bmatrix} \in \mathbb{R}^H.$$

Στην περίπτωση πενταετούς πρόβλεψης θεωρούμε ότι ένα χρηματιστηριακό έτος έχει περίπου 252 ημέρες συναλλαγών. Επομένως:

$$H = 5 \cdot 252 = 1260.$$

Αρα για κάθε ημέρα  $t$  το μοντέλο εκπαιδεύεται ώστε να προβλέψει:

$$\mathbf{y}_t = \left[ \ln \left( \frac{P_{t+1}}{P_t} \right), \ln \left( \frac{P_{t+2}}{P_t} \right), \dots, \ln \left( \frac{P_{t+1260}}{P_t} \right) \right]^T.$$

Η παραπάνω διατύπωση μετατρέπει το πρόβλημα σε πρόβλημα πολυμεταβλητής παλινδρόμησης, όπου κάθε δείγμα έχει μία είσοδο και  $H$  εξόδους.

### 3 Χαρακτηριστικά Εισόδου

Για κάθε ημέρα  $t$  δημιουργείται ένα διάνυσμα χαρακτηριστικών:

$$\mathbf{x}_t = \begin{bmatrix} x_t^{(1)} \\ x_t^{(2)} \\ \vdots \\ x_t^{(d)} \end{bmatrix} \in \mathbb{R}^d,$$

όπου  $d$  είναι το πλήθος των χαρακτηριστικών.

Τα αρχικά χαρακτηριστικά περιλαμβάνουν τις βασικές ημερήσιες τιμές:

$$Open_t, \quad High_t, \quad Low_t, \quad Close_t, \quad Volume_t.$$

Επιπλέον, υπολογίζονται παράγωγα χαρακτηριστικά. Η απλή ημερήσια απόδοση ορίζεται ως:

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}},$$

ενώ η ημερήσια λογαριθμική απόδοση είναι:

$$\ell_t = \ln \left( \frac{P_t}{P_{t-1}} \right).$$

Χρησιμοποιούνται επίσης κινητοί μέσοι όροι. Για παράδειγμα, ο κινητός μέσος όρος  $n$  ημερών δίνεται από:

$$MA_{n,t} = \frac{1}{n} \sum_{i=0}^{n-1} P_{t-i}.$$

Η απόκλιση της τρέχουσας τιμής από τον κινητό μέσο όρο μπορεί να γραφτεί ως:

$$D_{n,t} = \frac{P_t - MA_{n,t}}{MA_{n,t}}.$$

Τέτοια χαρακτηριστικά επιτρέπουν στο μοντέλο να έχει πληροφορία για την πρόσφατη τάση της τιμής.

Ένας ακόμη σημαντικός δείκτης είναι ο Relative Strength Index:

$$RSI_t = 100 - \frac{100}{1 + RS_t},$$

όπου:

$$RS_t = \frac{\text{μέσο κέρδος σε } n \text{ ημέρες}}{\text{μέση απώλεια σε } n \text{ ημέρες}}.$$

Ο δείκτης MACD υπολογίζεται ως διαφορά δύο εκθετικών κινητών μέσων:

$$MACD_t = EMA_{12,t} - EMA_{26,t}.$$

Το Average True Range χρησιμοποιείται ως μέτρο μεταβλητότητας:

$$ATR_t = \frac{1}{n} \sum_{i=0}^{n-1} TR_{t-i},$$

όπου το πραγματικό εύρος είναι:

$$TR_t = \max(|High_t - Low_t|, |High_t - Close_{t-1}|, |Low_t - Close_{t-1}|).$$

Συνολικά, το διάνυσμα χαρακτηριστικών  $\mathbf{x}_t$  περιέχει πληροφορία για την τιμή, την απόδοση, την τάση, τον όγκο και τη μεταβλητότητα.

## 4 Χρονοσειριακό Παράθυρο Εισόδου

Το μοντέλο δεν χρησιμοποιεί μόνο μία ημέρα ως είσοδο. Αντίθετα, χρησιμοποιεί ένα παράθυρο  $L$  διαδοχικών ημερών. Για κάθε ημερομηνία  $t$ , η είσοδος ορίζεται ως:

$$\mathbf{X}_t = \begin{bmatrix} \mathbf{x}_{t-L+1} \\ \mathbf{x}_{t-L+2} \\ \vdots \\ \mathbf{x}_t \end{bmatrix} \in \mathbb{R}^{L \times d}.$$

Στην παρούσα εργασία χρησιμοποιείται:

$$L = 60.$$

Άρα κάθε δείγμα εισόδου είναι ένας πίνακας διαστάσεων:

$$60 \times d.$$

Το αντίστοιχο διάνυσμα στόχου είναι:

$$\mathbf{y}_t = \begin{bmatrix} r_{t,1} \\ r_{t,2} \\ \vdots \\ r_{t,H} \end{bmatrix}.$$

Επομένως, το συνολικό πρόβλημα γράφεται ως:

$$f_{\theta} : \mathbb{R}^{L \times d} \rightarrow \mathbb{R}^H,$$

όπου  $f_{\theta}$  είναι το νευρωνικό μοντέλο με παραμέτρους  $\theta$ .

Η πρόβλεψη είναι:

$$\hat{\mathbf{y}}_t = f_{\theta}(\mathbf{X}_t).$$

Με άλλα λόγια, το μοντέλο λαμβάνει ως είσοδο τις τελευταίες  $L$  ημέρες και προβλέπει τις αποδόσεις για τις επόμενες  $H$  ημέρες.

## 5 Κανονικοποίηση Δεδομένων

Τα χαρακτηριστικά έχουν διαφορετικές κλίμακες. Για παράδειγμα, ο όγκος συναλλαγών μπορεί να είναι της τάξης εκατομμυρίων, ενώ ένας δείκτης όπως ο  $RSI$  παίρνει τιμές σε περιορισμένο διάστημα. Για αυτόν τον λόγο εφαρμόζεται κανονικοποίηση.

Η μέθοδος που χρησιμοποιείται είναι η Min--Max κανονικοποίηση:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}.$$

## 6 Χρονικός Διαχωρισμός Δεδομένων

Σε προβλήματα χρονοσειρών ο διαχωρισμός των δεδομένων πρέπει να διατηρεί τη χρονική σειρά. Αν γινόταν τυχαίος διαχωρισμός, τότε θα υπήρχε κίνδυνος το μοντέλο να εκπαιδευτεί σε μελλοντικές παρατηρήσεις και να αξιολογηθεί σε παλαιότερες.

Ορίζουμε τρία σύνολα:

$$\mathcal{D}_{train}, \quad \mathcal{D}_{val}, \quad \mathcal{D}_{test}.$$

Η χρονική σειρά είναι:

$$\mathcal{D}_{train} < \mathcal{D}_{val} < \mathcal{D}_{test}.$$

Το σύνολο εκπαίδευσης χρησιμοποιείται για την προσαρμογή των παραμέτρων  $\theta$ . Το σύνολο επικύρωσης χρησιμοποιείται για την επιλογή μοντέλου και το early stopping. Το σύνολο ελέγχου χρησιμοποιείται μόνο στο τέλος.

Το βέλτιστο μοντέλο υπολογίζεται ως:

$$\theta^* = \arg \min_{\theta} \mathcal{L}_{train}(\theta).$$

Στη συνέχεια, η τελική αξιολόγηση γίνεται στο:

$$\mathcal{D}_{test}.$$

Ένα σημαντικό σημείο είναι ότι για μέγιστο ορίζοντα  $H$  οι τελευταίες  $H$  ημέρες δεν μπορούν να χρησιμοποιηθούν ως πλήρη εποπτευμένα δείγματα. Αυτό συμβαίνει επειδή για μία ημέρα  $t$  απαιτείται να γνωρίζουμε την τιμή  $P_{t+H}$ . Αν αυτή η τιμή δεν υπάρχει στα δεδομένα, τότε δεν μπορεί να κατασκευαστεί ο στόχος.

Αρα, όσο μεγαλώνει ο ορίζοντας  $H$ , τόσο μειώνεται το πλήθος των διαθέσιμων δειγμάτων.

## 7 Άμεση Πολυ-Εξοδική Πρόβλεψη

Η βασική προσέγγιση της εργασίας είναι η άμεση πολυ-εξοδική πρόβλεψη. Το μοντέλο παράγει όλες τις μελλοντικές αποδόσεις ταυτόχρονα:

$$f_{\theta}(\mathbf{X}_t) = \begin{bmatrix} \hat{r}_{t,1} \\ \hat{r}_{t,2} \\ \vdots \\ \hat{r}_{t,H} \end{bmatrix}.$$

Η μέθοδος αυτή διαφέρει από την αναδρομική πρόβλεψη. Στην αναδρομική πρόβλεψη, το μοντέλο θα προέβλεπε πρώτα την επόμενη ημέρα:

$$\hat{P}_{t+1} = g(P_t),$$

έπειτα θα χρησιμοποιούσε αυτή την πρόβλεψη για την επόμενη:

$$\hat{P}_{t+2} = g(\hat{P}_{t+1}),$$

και γενικά:

$$\hat{P}_{t+k} = g(\hat{P}_{t+k-1}).$$

Το πρόβλημα είναι ότι τα σφάλματα συσσωρεύονται. Αν η πρώτη πρόβλεψη είναι λανθασμένη, τότε αυτό επηρεάζει όλες τις επόμενες.

Στην άμεση πολυ-εξοδική προσέγγιση έχουμε:

$$\mathbf{X}_t \longrightarrow (\hat{r}_{t,1}, \hat{r}_{t,2}, \dots, \hat{r}_{t,H}).$$

Άρα όλες οι προβλέψεις προκύπτουν από το ίδιο πραγματικό ιστορικό παράθυρο. Δεν χρησιμοποιούνται μελλοντικές προβλέψεις ως νέα είσοδος.

Αυτό είναι σημαντικό στις χρηματοοικονομικές χρονοσειρές, διότι οι μελλοντικοί τεχνικοί δείκτες, όπως μελλοντικός *RSI*, μελλοντικός *MACD* ή μελλοντικοί κινητοί μέσοι όροι, δεν είναι γνωστοί.

## 8 Convolutional Neural Network (CNN)

Το πρώτο μοντέλο είναι ένα Convolutional Neural Network. Αν η είσοδος είναι:

$$\mathbf{X}_t \in \mathbb{R}^{L \times d},$$

τότε ένα μονοδιάστατο convolution φίλτρο υπολογίζει:

$$z_i^{(m)} = \sigma \left( \sum_{j=0}^{q-1} \sum_{k=1}^d w_{j,k}^{(m)} x_{i+j,k} + b^{(m)} \right),$$

όπου:

- $q$  είναι το μέγεθος του φίλτρου,
- $m$  είναι ο δείκτης του φίλτρου,

- $w_{j,k}^{(m)}$  είναι τα βάρη,
- $b^{(m)}$  είναι η πόλωση,
- $\sigma$  είναι η συνάρτηση ενεργοποίησης.

Τα convolution φίλτρα εντοπίζουν τοπικά χρονικά μοτίβα. Σε χρηματοοικονομικές χρονοσειρές τέτοια μοτίβα μπορεί να είναι:

βραχυπρόθεσμη τάση, απότομη μεταβολή, αύξηση μεταβλητότητας.

Μετά τα convolution επίπεδα, η έξοδος μετατρέπεται σε διάνυσμα και περνά από πλήρως συνδεδεμένα επίπεδα:

$$\hat{\mathbf{y}}_t = W\mathbf{h}_t + \mathbf{b},$$

όπου  $\mathbf{h}_t$  είναι η ενδιάμεση αναπαράσταση που παράγεται από το CNN.

## 9 Time Delay Neural Network (TDNN)

Το δεύτερο μοντέλο είναι το Time Delay Neural Network. Η βασική ιδέα είναι ότι το μοντέλο χρησιμοποιεί συγκεκριμένες χρονικές καθυστερήσεις της εισόδου.

Έστω σύνολο καθυστερήσεων:

$$\Delta = \{\delta_1, \delta_2, \dots, \delta_m\}.$$

Τότε μπορεί να κατασκευαστεί διάνυσμα:

$$\mathbf{u}_t = [\mathbf{x}_{t-\delta_1}, \mathbf{x}_{t-\delta_2}, \dots, \mathbf{x}_{t-\delta_m}].$$

Η πρόβλεψη δίνεται από:

$$\hat{\mathbf{y}}_t = f_{\theta}(\mathbf{u}_t).$$

Οι μικρές καθυστερήσεις μπορούν να συλλάβουν βραχυπρόθεσμες επιδράσεις, ενώ οι μεγαλύτερες καθυστερήσεις μπορούν να συλλάβουν πιο αργές μεταβολές. Έτσι, το TDNN μπορεί να θεωρηθεί ως μοντέλο που εξετάζει διαφορετικές χρονικές κλίμακες της χρονοσειράς.

## 10 Μοντέλο CNN--LSTM

Το τρίτο μοντέλο συνδυάζει CNN και LSTM. Πρώτα, το CNN εξάγει τοπικά χαρακτηριστικά:

$$\mathbf{Z}_t = CNN(\mathbf{X}_t).$$

Στη συνέχεια, το LSTM επεξεργάζεται την ακολουθία χαρακτηριστικών. Οι βασικές εξισώσεις ενός LSTM κελιού είναι:

$$\mathbf{i}_t = \sigma(W_i \mathbf{z}_t + U_i \mathbf{h}_{t-1} + \mathbf{b}_i),$$

$$\mathbf{f}_t = \sigma(W_f \mathbf{z}_t + U_f \mathbf{h}_{t-1} + \mathbf{b}_f),$$

$$\mathbf{o}_t = \sigma(W_o \mathbf{z}_t + U_o \mathbf{h}_{t-1} + \mathbf{b}_o),$$

$$\tilde{\mathbf{c}}_t = \tanh(W_c \mathbf{z}_t + U_c \mathbf{h}_{t-1} + \mathbf{b}_c),$$



$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t,$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t).$$

Η τελική πρόβλεψη είναι:

$$\hat{\mathbf{y}}_t = W\mathbf{h}_t + \mathbf{b}.$$

Το πλεονέκτημα του CNN--LSTM είναι ότι συνδυάζει δύο επίπεδα πληροφορίας. Το CNN εντοπίζει τοπικά μοτίβα, ενώ το LSTM μοντελοποιεί χρονικές εξαρτήσεις μεγαλύτερης διάρκειας.

## 11 Loss function

Για κάθε δείγμα  $t$ , η πραγματική έξοδος είναι:

$$\mathbf{y}_t = (y_{t,1}, y_{t,2}, \dots, y_{t,H}),$$

και η πρόβλεψη:

$$\hat{\mathbf{y}}_t = (\hat{y}_{t,1}, \hat{y}_{t,2}, \dots, \hat{y}_{t,H}).$$

Το σφάλμα για τον ορίζοντα  $k$  είναι:

$$e_{t,k} = \hat{y}_{t,k} - y_{t,k}.$$

Χρησιμοποιείται η συνάρτηση κόστους Huber:

$$\ell_\delta(e) = \begin{cases} \frac{1}{2}e^2, & |e| \leq \delta, \\ \delta(|e| - \frac{1}{2}\delta), & |e| > \delta. \end{cases}$$

Η Huber loss είναι χρήσιμη επειδή συμπεριφέρεται σαν τετραγωνικό σφάλμα για μικρές αποκλίσεις, αλλά είναι λιγότερο ευαίσθητη σε ακραίες τιμές σε σχέση με το καθαρό MSE.

Η συνολική συνάρτηση κόστους είναι:

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{t=1}^N \sum_{k=1}^H w_k \ell_\delta(\hat{y}_{t,k} - y_{t,k}).$$

## 12 Βελτιστοποίηση

Η εκπαίδευση αντιστοιχεί στο πρόβλημα:

$$\theta^* = \arg \min_{\theta} \mathcal{L}(\theta).$$

Η ενημέρωση των παραμέτρων γίνεται με βάση την κλίση της συνάρτησης κόστους:

$$\theta_{n+1} = \theta_n - \eta \nabla_{\theta} \mathcal{L}(\theta_n),$$

όπου  $\eta$  είναι ο ρυθμός μάθησης.

Στην πράξη χρησιμοποιείται ο Adam optimizer, ο οποίος προσαρμόζει τον ρυθμό μάθησης για κάθε παράμετρο με βάση τις πρώτες και δεύτερες ροπές των gradients.

Επιπλέον, χρησιμοποιείται early stopping. Αν το σφάλμα επικύρωσης:

$$\mathcal{L}_{val}$$

δεν βελτιωθεί για συγκεκριμένο αριθμό εποχών, η εκπαίδευση σταματά και κρατούνται οι παράμετροι με το μικρότερο validation loss.

## 13 Ανακατασκευή Προβλεπόμενης Τιμής

Το μοντέλο εξάγει προβλέψεις στον χώρο των λογαριθμικών αποδόσεων. Για την απεικόνιση των αποτελεσμάτων σε τιμές, χρησιμοποιείται η σχέση:

$$\hat{P}_{t+k} = P_t e^{\hat{r}_{t,k}}.$$

Έτσι το προβλεπόμενο μελλοντικό μονοπάτι γράφεται ως:

$$\hat{\mathbf{P}}_t = (\hat{P}_{t+1}, \hat{P}_{t+2}, \dots, \hat{P}_{t+H}).$$

Για  $H = 1260$ , το μοντέλο παράγει μία ημερήσια πρόβλεψη για περίπου πέντε έτη:

$$\hat{\mathbf{P}}_t = (\hat{P}_{t+1}, \hat{P}_{t+2}, \dots, \hat{P}_{t+1260}).$$

Τα βασικά χρονικά σημεία που μπορούν να σημειωθούν στο γράφημα είναι:

$$1d = 1,$$

$$1m \approx 21,$$

$$1y \approx 252,$$

$$5y \approx 1260.$$

Οι μελλοντικές ημερομηνίες χρησιμοποιούνται μόνο στον άξονα  $x$  του γραφήματος. Δεν αποτελούν είσοδο του μοντέλου.

## 14 Εκτίμηση Αβεβαιότητας

Για εκτίμηση αβεβαιότητας χρησιμοποιείται Monte Carlo Dropout. Κατά την πρόβλεψη, το dropout παραμένει ενεργό και η ίδια είσοδος περνά από το μοντέλο  $M$  φορές:

$$\hat{\mathbf{y}}_t^{(1)}, \hat{\mathbf{y}}_t^{(2)}, \dots, \hat{\mathbf{y}}_t^{(M)}.$$

Η μέση πρόβλεψη είναι:

$$\bar{\mathbf{y}}_t = \frac{1}{M} \sum_{m=1}^M \hat{\mathbf{y}}_t^{(m)}.$$

Για κάθε ορίζοντα  $k$ , η τυπική απόκλιση είναι:

$$s_k = \sqrt{\frac{1}{M-1} \sum_{m=1}^M \left( \hat{y}_{t,k}^{(m)} - \bar{y}_{t,k} \right)^2}.$$

Ένα προσεγγιστικό διάστημα αβεβαιότητας 95% για τη λογαριθμική απόδοση είναι:

$$\bar{y}_{t,k} \pm 1.96 s_k.$$

Μετατροπή σε τιμή δίνει:

$$\hat{P}_{lower,t+k} = P_t \exp(\bar{y}_{t,k} - 1.96 s_k),$$

και

$$\hat{P}_{upper,t+k} = P_t \exp(\bar{y}_{t,k} + 1.96 s_k).$$

Άρα το τελικό γράφημα μπορεί να περιέχει την κεντρική πρόβλεψη και μία περιοχή αβεβαιότητας γύρω από αυτή.

## 15 Baseline Μοντέλα

Για να αξιολογηθεί αν τα νευρωνικά μοντέλα έχουν ουσιαστική αξία, συγκρίνονται με απλές baseline μεθόδους.

Η πρώτη baseline είναι η μηδενική απόδοση:

$$\hat{r}_{t,k} = 0.$$

Αυτό αντιστοιχεί στην υπόθεση:

$$\hat{P}_{t+k} = P_t.$$

Δηλαδή το μοντέλο υποθέτει ότι η τιμή θα παραμείνει σταθερή.

Η δεύτερη baseline είναι η μέση ιστορική απόδοση:

$$\hat{r}_{t,k} = \frac{1}{N} \sum_{i=1}^N r_{i,k}.$$

Αν ένα νευρωνικό μοντέλο δεν έχει καλύτερη απόδοση από αυτές τις απλές μεθόδους, τότε η αυξημένη πολυπλοκότητά του δεν δικαιολογείται.

## 16 Πειραματικός Σχεδιασμός

Η αξιολόγηση δεν πρέπει να γίνεται μόνο σε μία περίοδο αγοράς. Για αυτόν τον λόγο μπορούν να χρησιμοποιηθούν διαφορετικά σενάρια:

ομαλή ανοδική τάση,

απότομη πτώση αγοράς,

περίοδος υψηλής μεταβλητότητας,

εταιρικό ή εξωτερικό σοκ.

Για κάθε πείραμα ορίζεται ημερομηνία πρόβλεψης  $t_0$ . Το μοντέλο χρησιμοποιεί μόνο τα δεδομένα μέχρι το  $t_0$ :

$$\mathbf{X}_{t_0} = (\mathbf{x}_{t_0-L+1}, \dots, \mathbf{x}_{t_0}).$$

Η πρόβλεψη είναι:

$$\hat{\mathbf{y}}_{t_0} = f_{\theta}(\mathbf{X}_{t_0}).$$

Στη συνέχεια, η προβλεπόμενη τροχιά συγκρίνεται με την πραγματική μελλοντική τιμή:

$$P_{t_0+1}, P_{t_0+2}, \dots, P_{t_0+H}.$$

Με αυτόν τον τρόπο ελέγχεται αν το μοντέλο μπορεί να ακολουθήσει τη μελλοντική συμπεριφορά της αγοράς.

Είναι σημαντικό να τονιστεί ότι ένα μοντέλο που βασίζεται μόνο σε ιστορικές τιμές και τεχνικούς δείκτες δεν μπορεί να γνωρίζει μελλοντικές ειδήσεις. Άρα σε περιπτώσεις απότομων γεγονότων, όπως ξαφνικές ανακοινώσεις ή κρίσεις, το μοντέλο αναμένεται να δυσκολεύεται.

## 17 Περιορισμοί

Ο πρώτος περιορισμός είναι ότι οι χρηματιστηριακές αγορές δεν είναι στάσιμες. Δηλαδή η κατανομή των δεδομένων μεταβάλλεται με τον χρόνο:

$$P(\mathbf{X}_t, \mathbf{y}_t) \neq P(\mathbf{X}_{t+\tau}, \mathbf{y}_{t+\tau}).$$

Αυτό σημαίνει ότι ένα μοντέλο που εκπαιδεύτηκε σε μία περίοδο μπορεί να μην αποδίδει το ίδιο καλά σε μία άλλη περίοδο.

Ο δεύτερος περιορισμός είναι ότι οι εξωτερικές πληροφορίες δεν περιλαμβάνονται στα χαρακτηριστικά. Το μοντέλο γνωρίζει μόνο:

$$Open, High, Low, Close, Volume$$

και τεχνικούς δείκτες που παράγονται από αυτά. Δεν γνωρίζει νέα, οικονομικές ανακοινώσεις ή αλλαγές επιτοκίων.

Ο τρίτος περιορισμός είναι ότι μεγάλοι χρονικοί ορίζοντες απαιτούν πολλά ιστορικά δεδομένα. Για πρόβλεψη πέντε ετών χρειάζεται:

$$P_{t+1260}.$$

Επομένως, οι πιο πρόσφατες ημερομηνίες δεν μπορούν να χρησιμοποιηθούν ως πλήρως εποπτευμένα δείγματα για πενταετή πρόβλεψη.

## 18 Αποτελέσματα

Στην ενότητα αυτή παρουσιάζονται τα αποτελέσματα της μεθόδου πρόβλεψης σε διαφορετικές μετοχές και χρηματιστηριακές περιόδους. Ο στόχος δεν είναι μόνο να εξεταστεί αν το μοντέλο προβλέπει σωστά μία τελική τιμή, αλλά να μελετηθεί η συνολική μορφή της προβλεπόμενης μελλοντικής τροχιάς.

Σε κάθε πείραμα, το μοντέλο χρησιμοποιεί ως είσοδο το τελευταίο διαθέσιμο ιστορικό παράθυρο 60 ημερών πριν από την ημερομηνία πρόβλεψης. Η έξοδος του μοντέλου είναι ένα διάνυσμα προβλεπόμενων λογαριθμικών αποδόσεων:

$$\hat{\mathbf{y}}_t = (\hat{r}_{t,1}, \hat{r}_{t,2}, \dots, \hat{r}_{t,H}),$$

όπου  $H$  είναι ο μέγιστος χρονικός ορίζοντας πρόβλεψης.


Οι προβλεπόμενες αποδόσεις μετατρέπονται σε προβλεπόμενες τιμές μέσω της σχέσης:

$$\hat{P}_{t+k} = P_t e^{\hat{r}_{t,k}}.$$


Στα γραφήματα, η μπλε καμπύλη αντιστοιχεί στην πραγματική τιμή της μετοχής, ενώ η πορτοκαλί καμπύλη αντιστοιχεί στην προβλεπόμενη πορεία του μοντέλου. Η διακεκομμένη κάθετη γραμμή δείχνει την ημερομηνία εκκίνησης της πρόβλεψης, ενώ η σκιασμένη περιοχή δείχνει την περίοδο εκπαίδευσης ή το διάστημα αβεβαιότητας της πρόβλεψης.

Πίνακας 1: Πειραματικές ρυθμίσεις των προβλέψεων.

| <b>Ticker</b> | <b>Prediction Start</b> | <b>Prediction End</b> | <b>Σκοπός πειράματος</b>      |
|---------------|-------------------------|-----------------------|-------------------------------|
| SPY           | 2020-02-19              | 2024-12-18            | Broad market crash / recovery |
| AAPL          | 2020-02-18              | 2024-12-17            | Large-cap technology stock    |
| XOM           | 2020-02-20              | 2024-12-19            | Energy sector recovery        |
| MSFT          | 2020 περίπου            | 2025 περίπου          | Stable growth example         |
| KO            | 2021-01-22              | 2025-11-21            | Defensive stock               |
| CRM           | 2021-01-22              | 2025-11-21            | Growth stock with volatility  |
| GME           | 2021-01-22              | 2025-11-21            | Extreme short-squeeze case    |
| NVDA          | 2023-05-24              | 2023-11-16            | Short-term momentum test      |
| META          | 2022-02-02              | 2022-07-28            | Short-term crash test         |
| UNH           | 2025-04-16              | 2025-07-14            | Short-term company shock      |



Σχήμα 1: SPY




Σχήμα 2: AAPL

Σχήμα 3: Πενταετής πρόβλεψη για SPY και AAPL. Και στις δύο περιπτώσεις η πρόβλεψη ξεκινά λίγο πριν από την έντονη μεταβλητότητα της περιόδου COVID-19.




Σχήμα 4: XOM




Σχήμα 5: MSFT

Σχήμα 6: Σύγκριση πρόβλεψης για XOM και MSFT. Η XOM αντιπροσωπεύει πιο κυκλικό ενεργειακό τίτλο, ενώ η MSFT αντιπροσωπεύει μετοχή τεχνολογίας με πιο σταθερή μακροχρόνια τάση.




Σχήμα 7: KO




Σχήμα 8: CRM

Σχήμα 9: Σύγκριση μεταξύ αμυντικής μετοχής και μετοχής ανάπτυξης. Η KO εμφανίζει πιο ομαλή συμπεριφορά, ενώ η CRM παρουσιάζει μεγαλύτερη μεταβλητότητα μετά την ημερομηνία πρόβλεψης.






Σχήμα 10: GME




Σχήμα 11: META

Σχήμα 12: Περιπτώσεις υψηλής μεταβλητότητας και εξωτερικών σοκ. Η GME αποτελεί ακραίο παράδειγμα λόγω short squeeze, ενώ η META εξετάζει απότομη πτώση μετά από εταιρικά νέα.



Σχήμα 13: NVDA



Σχήμα 14: UNH

Σχήμα 15: Βραχυπρόθεσμα stress tests. Η NVDA εξετάζει περίοδο έντονης ανοδικής ορμής, ενώ η UNH εξετάζει απότομη εταιρική πτώση.

## 19 Συμπεράσματα

Από τα αποτελέσματα παρατηρείται ότι η συμπεριφορά του μοντέλου διαφέρει σημαντικά ανάλογα με τη μετοχή και την περίοδο πρόβλεψης. Σε τίτλους με πιο ομαλή μακροχρόνια τάση, όπως ο SPY, η MSFT και σε κάποιο βαθμό η KO, η προβλεπόμενη καμπύλη ακολουθεί καλύτερα τη γενική κατεύθυνση της πραγματικής τιμής. Αυτό δείχνει ότι το μοντέλο μπορεί να αποτυπώσει μέρος της μακροχρόνιας τάσης όταν η αγορά κινείται σχετικά ομαλά.

Αντίθετα, σε περιπτώσεις υψηλής μεταβλητότητας ή εξωτερικών γεγονότων, όπως η GME, η META και η UNH, η απόκλιση μεταξύ πρόβλεψης και πραγματικής τιμής είναι μεγαλύτερη. Αυτό είναι αναμενόμενο, επειδή το μοντέλο χρησιμοποιεί μόνο ιστορικές τιμές και τεχνικούς

δείκτες. Δεν έχει πρόσβαση σε πληροφορίες όπως εταιρικές ανακοινώσεις, νέα αγορές, αλλαγές κερδοφορίας ή γεγονότα που προκαλούν απότομη μεταβολή της τιμής.

Η περίπτωση του GME αποτελεί χαρακτηριστικό παράδειγμα περιορισμού της μεθόδου. Η κίνηση της τιμής επηρεάστηκε από εξαιρετικά ασυνήθιστες συνθήκες αγοράς, οι οποίες δεν μπορούν να εξαχθούν μόνο από τα ιστορικά τεχνικά χαρακτηριστικά. Παρόμοια, η περίπτωση της UNH δείχνει ότι ένα ξαφνικό εταιρικό σοκ μπορεί να οδηγήσει σε απότομη πτώση, την οποία το μοντέλο δεν είναι απαραίτητο να έχει τη δυνατότητα να προβλέψει.

Στην περίπτωση της XOM, το μοντέλο προβλέπει αρχικά πτώση και στη συνέχεια ανάκαμψη, γεγονός που δείχνει ότι μπορεί να συλλάβει σε κάποιο βαθμό τη μεταβολή της τάσης μετά από περίοδο κρίσης. Ωστόσο, η πραγματική πορεία της τιμής παρουσιάζει ισχυρότερη ανάκαμψη από αυτή που προβλέπει το μοντέλο.

Συνολικά, τα αποτελέσματα δείχνουν ότι η μέθοδος είναι πιο κατάλληλη για την εκτίμηση γενικής τάσης παρά για την ακριβή πρόβλεψη απότομων και απρόβλεπτων γεγονότων. Η προβλεπόμενη τροχιά πρέπει να ερμηνεύεται ως εκτίμηση βασισμένη στα ιστορικά δεδομένα και όχι ως βέβαιη μελλοντική εξέλιξη.

Η πειραματική αξιολόγηση δείχνει ότι η άμεση πολυ-εξοδική πρόβλεψη μπορεί να παράγει μία συνεχή μελλοντική καμπύλη τιμών για πολλούς χρονικούς ορίζοντες. Το μοντέλο λειτουργεί καλύτερα σε περιόδους όπου η μελλοντική πορεία έχει συνέχεια με την ιστορική τάση. Αντίθετα, σε περιόδους όπου η τιμή επηρεάζεται από ξαφνικά εξωτερικά γεγονότα, η ακρίβεια μειώνεται.

Αυτό επιβεβαιώνει έναν βασικό περιορισμό της μεθόδου: τα τεχνικά χαρακτηριστικά περιέχουν πληροφορία για την παρελθοντική συμπεριφορά της αγοράς, αλλά δεν περιέχουν πληροφορία για μελλοντικές ειδήσεις ή απρόβλεπτα γεγονότα.

## 20 Python Code

Όλοι οι κώδικες του project συμπεριλαμβανομένου και του gui είναι στο ακόλουθο Link:

[Project GitHub Repository](#)